

CUDA PROGRAMMING FOR NVIDIA H100S

CUDA Programming for NVIDIA H100s

Prateek Shukla · 简体中文版

先修要求

- 理解 C/C++ 语法
- 对旧架构与同步 CUDA 执行模型有可用的理解。如果你写不出一个标准的 kernel,就很难理解异步模型。
- 线性代数,尤其是矩阵乘法运算与基本内存布局。必须理解分块(tile)matmul。
- 对 Transformer 和 MLP 有基本理解会大有帮助,但不是硬性要求。知道我们为什么要优化这些特定的矩阵运算,能加速你对瓶颈的理解。

每节课你应该准备什么

这门课的大部分时间里,有两样东西需要一直开着:

- 一本笔记本和一支笔,用来构建心智模型
- 一个 AI 助手

心智模型是你对各个组件如何工作的解读,是看待现实的压缩表达。当你面对一团乱麻的局面时,不用死记硬背也能预判什么是关键。

AI 助手的作用是打磨你的心智模型。每一次当你的心智模型与现实不符、或者心里有怀疑时,就必须去找 AI 模型验证你的心智模型。

Prateek 的课程完成建议

- 大多数问题都源于糟糕的基础/心智模型。所以无论何时卡住了,把你所有的疑问都抛给 AI 模型。
- 不要试图一次理解所有东西。那是个陷阱。你的任务不是同时精通 Hopper、CUTLASS、fast.cu 和 ThunderKittens。你的任务是搭一段楼梯。
- 在前几课里,你不需要“完全理解”所有内容。你要做的是拿到地图;后面的课程补充机制;再后面的代码给出具体的现实。如果你觉得第 1 课就必须完整无缺,那么第 8 课变得棘手时你就会恐慌。
- 用 AI agent 学习代码库——它们是你能得到的、对代码和各种原语最接近准确的信息来源。

目录

- 1. H100 简介
- 2. 集群、数据类型、内联 PTX、指针
- 3. 异步与屏障
- 4. cuTensorMap
- 5. cp.async.bulk
- 6. WGMMA-1
- 7. WGMMA-2
- 8. 内核设计(Kernel Design)
- 9. 多 GPU 第 1 部分
- 10. 多 GPU 第 2 部分

第 1 课 — H100 简介

对 NVIDIA H100 GPU 的技术性介绍,聚焦其内部架构、硬件组件,以及向异步执行的重大转变。

- 核心架构与规格
- 关键技术创新
- 内存与执行层级
- 运行逻辑

第 2 课 — 集群、数据类型、内联 **PTX**、指针

深入编程与内存模型。覆盖四个主要领域:线程块集群、内联 PTX、内存状态空间与硬件同步。

- 线程块集群(Thread Block Clusters)
- 并行线程执行(PTX)与内联 PTX
- 状态空间与数据类型

第 3 课 — 异步与屏障

本课聚焦异步性与硬件屏障,详解 NVIDIA H100 如何管理快速计算单元与相对较慢的内存访问之间的巨大速度差距。

- 异步的哲学
- 防止内存冒险(hazard)
- mbarrier:数据驱动的不同步
- 高级同步模式

第 4 课 — cuTensorMap

第 4 课深入探讨张量内存加速器(TMA)与 cuTensorMap——它们是让 H100 实现标志性异步数据搬运的硬件与软件组件。

- 什么是 TMA?
- cuTensorMap 描述符
- cuTensorMap 中的关键优化特性(swizzle、L2 promotion、interleaving 等)

第 5 课 — **cp.async.bulk**

本课讲 PTX 指令 `cp.async.bulk`:它利用 TMA 与 `cuTensorMap` 完成批量异步拷贝。我们会讨论异步数据搬运的创新、核心拷贝指令以及各种变体。

- 核心概念:`cp.async.bulk` 与 TMA
- Hopper(TMA)vs. Ampere(LSU)
- 数据布局:非结构化 vs. 结构化
- 同步与完成机制
- L2 缓存提示与多播(multicast)
- 预取与异步规约

第 6 课 — WGMMA-1

本课聚焦在 Hopper GPU 上用 Warp Group Matrix Multiply Accumulate(WGMMA)执行真正的数学运算。

- 范式转变:从 warp 到 warpgroup
- 核心指令:wmma.mma_async
- 取矩阵 A:寄存器 vs. 共享内存
- 用 Idmatrix 管理寄存器
- WGMMA 描述符

第 7 课 — WGMMA 第 2 部分

本课收尾 Hopper 的数学流水线,覆盖同步、结果存储,以及低精度与稀疏操作的种种细节。

- 用 WGMMA 组(group)做流水线
- 存储输出:stmatrix
- FP8 范式转变
- FP8 的怪癖:打包(pack)与 K-major 布局
- 稀疏 WGMMA

第 8 课 — 内核设计

关于高性能内核设计的一课,专门聚焦计算受限(compute-bound)内核的优化。核心理念围绕 warp 特化、流水线与持久化调度展开,目标是让 GPU 的张量核心利用率接近 100%。

- 计算受限内核的分类与“脊点”(ridge point)
- warp 特化(warp specialization)
- 循环缓冲与流水线
- 智能调度
- Epilogue 与多内核优化

代码

课程中引用的代码锚点:

- `sm90_pipeline.hpp(cutlass)`
- `sm90_gemm_tma_warpspecialized_pingpong.hpp(cutlass)`
- `sm90_gemm_tma_warpspecialized_cooperative.hpp(cutlass)`
- `sm90_mma_tma_gmma_ss_warpspecialized.hpp(cutlass)`
- `sm90_mma_tma_gmma_rs_warpspecialized.hpp(cutlass)`
- `sm90_tile_scheduler.hpp(cutlass)`
- `sm90_tile_scheduler_group.hpp(cutlass)`
- `sm90_tile_scheduler_stream_k.hpp(cutlass)`
- `sm90_tma_epilogue_warpspecialized(cutlass)`
- `sm90_builder.inl(cutlass)`
- `fast.cu(matmul_12.cuh)`

第 9 课 — 多 GPU 第 1 部分

本课讲把多块 GPU 融合成单个巨型执行引擎所用的具体技术。

- 单 GPU 的计算瓶颈
- 节点内部组网(NVLink 与 NVSwitch)
- 扩展互联网络(节点之间)
- CUDA P2P 与 MPI

第 10 课 — 多 GPU 第 2 部分

本课讲让裸硬件像单一执行引擎那样运转所需的编排与通信软件。我们梳理任务管理器如何分配资源、如何把彼此隔离的进程互相介绍认识,然后学习训练期间在集群中搬移张量数据所用的具体原语与数学。

- 集群编排(Slurm + PMIx)
- 网络初始化(NCCL 设置)
- 四种并行范式
- 通信原语